
Terminal-Bench 4.0
Codex · GPT-5.6-Luna-max
Codex · GPT-5.6-Terra-max
Codex · GPT-5.6-Sol-max
Claude-Code · GLM-5.3-max
Grok-Build · Grok-4.6
Claude-Code · Opus-5-max
Claude-Code · Fable-5.1-max
Claude-Code · Opus-4.8-max
10^0
10^1
Budget per task ($)
DeepSWE
DeepSeek-v4-Flash (max)
DeepSeek-v4-Pro (max)
GLM-5-3-Flash (max)
10^{-1}
2×10^{-1}
3×10^{-1}
Budget per task ($)
100
75
50
25
0
Revenue share (%)